

Report progetto Architetture Dati: data drift su ImageNet

Daniele Besozzi 894998, Andrea Consonni 900116, Elena Zen 895355

Capitolo 1

Introduzione al problema

I sistemi di Machine Learning vengono generalmente sviluppati assumendo che i dati osservati durante l'addestramento siano rappresentativi di quelli che il modello incontrerà durante il suo utilizzo. Nelle applicazioni reali, tuttavia, questa assunzione è spesso disattesa: le caratteristiche della distribuzione dei dati possono variare nel tempo o tra differenti contesti di utilizzo. Questo fenomeno, comunemente indicato come **data drift** o **distribution shift**, può determinare una significativa riduzione delle prestazioni del modello anche in assenza di modifiche alla sua architettura o ai suoi parametri.

Lo studio della robustezza rispetto al **data drift** rappresenta pertanto un aspetto fondamentale nella valutazione di sistemi di Machine Learning. È infatti importante non limitarsi a misurare le prestazioni su dati provenienti dalla stessa distribuzione utilizzata in fase di training (**in-distribution**), ma valutare anche il comportamento del modello in presenza di variazioni nella distribuzione degli input (**out-of-distribution**). Tali variazioni possono assumere forme differenti, includendo cambiamenti nelle condizioni di acquisizione delle immagini, nella loro qualità, nello stile visivo o nella presenza di specifiche perturbazioni.

In questo progetto, l'effetto del **data drift** sulle prestazioni dei modelli di classificazione d'immagini è stato analizzato attraverso una serie di benchmark basati sulla famiglia di dataset ImageNet. In particolare, sono stati considerati **ImageNet**, utilizzato come riferimento per la valutazione **in-distribution**, **ImageNet-R**, progettato per valutare la robustezza del modello rispetto a variazioni nella rappresentazione visiva degli oggetti, e **ImageNet-C**, che introduce diverse tipologie di corruzioni comuni applicate alle immagini. La combinazione di questi benchmark consente di analizzare il comportamento del modello in presenza di forme differenti di **distribution shift**, distinguendo tra variazioni di stile e rappresentazione e perturbazioni che simulano degradazioni o condizioni avverse nell'acquisizione dei dati.

L'obiettivo dell'analisi è quindi quantificare quanto il cambiamento nella distribuzione degli input influenzi le prestazioni del modello rispetto allo scenario di riferimento.

1.1 Definizioni di data drift

Nel machine learning supervisionato applicato a scenari reali, l'assunzione fondamentale per garantire la capacità di generalizzazione di un modello è che i dati di addestramento e i dati su cui il modello opererà una volta rilasciato siano indipendenti e identicamente distribuiti (i.i.d.) [3, 4]. Tuttavia, negli scenari applicativi reali, questa assunzione teorica viene costantemente violata. Le discrepanze tra l'ambiente controllato di laboratorio e le condizioni dinamiche del mondo reale, indotte da fattori quali distorsioni nella raccolta dei dati (sample selection bias), ambienti non stazionari o evoluzioni temporali e spaziali, causano variazioni nelle distribuzioni dei dati.

La letteratura scientifica ha storicamente sofferto di una frammentazione terminologica, utilizzando in modo intercambiabile nomi diversi per definire concetti analoghi (es. concept drift, population drift, changing environments, data fracture) [3]. In questo progetto adottiamo la seguente definizioni proposte da Moreno-Torres et al. [3]:

Definizione 1 (Dataset shift). *Si verifica quando la distribuzione di probabilità congiunta delle feature (o covariate) x e della variabile target (classe) y differisce tra la fase di addestramento (P_{tr}) e la fase di test (P_{tst}). Formalmente, $P_{tr}(y, x) \neq P_{tst}(y, x)$.*

Per poter analizzare e risolvere questo problema, è necessario distinguere la direzione causale tra la classe y e le feature x . Si identificano quindi due classi di problemi:

- Problemi $X \rightarrow Y$, in cui la classe y è determinata causalmente dal valore delle feature x (es. la rilevazione delle frodi bancarie, dove il comportamento dell'utente determina se c'è una frode).
- Problemi $Y \rightarrow X$, in cui la classe y determina causalmente il valore delle feature x (tipico della diagnostica medica, in cui la patologia y causa i sintomi osservabili x)

1.2 Tipologie di data drift

Il data drift può manifestarsi in diverse forme, a seconda della natura delle variazioni nella distribuzione dei dati. In questa sezione presentiamo le principali tipologie di data drift identificate in letteratura.

1.2.1 Covariate shift (o Population Drift)

Il covariate shift si riferisce al cambiamento della distribuzione delle variabili di input (o covariate) x tra la fase di training e quella di test, mentre la relazione condizionata che mappa l'input alla classe rimane del tutto invariata. Formalmente:

Definizione 2 (Covariate shift). *Appare solamente nei problemi del tipo $X \rightarrow Y$ e si verifica nel caso in cui $P_{tr}(x) \neq P_{tst}(x)$ e $P_{tr}(y|x) = P_{tst}(y|x)$*

Ad esempio, un modello di classificazione d'immagini addestrato principalmente su foto di cani su uno sfondo erboso che viene poi testato su immagini di cani che indossano impermeabili in contesti urbani [4]. Le feature visive di sfondo e i dettagli superficiali cambiano ($P(x)$ muta), ma il concetto semantico di "cane" associato a quelle immagini rimane lo stesso ($P(y|x)$ è costante).



Figura 1.1: Esempio di covariate shift

1.2.2 Prior probability shift

Il prior probability shift rappresenta il caso duale del covariate shift, focalizzato sul cambiamento della distribuzione della variabile target y , mentre la distribuzione condizionata delle feature data la classe rimane costante. Formalmente:

Definizione 3 (Prior probability shift). *Appare solamente nei problemi del tipo $Y \rightarrow X$ e si verifica nel caso in cui $P_{tr}(y) \neq P_{tst}(y)$ e $P_{tr}(x|y) = P_{tst}(x|y)$.*

Ad esempio, in un sistema di diagnostica medica per una specifica malattia infettiva, la distribuzione dei sintomi per i soggetti malati e sani rimane costante ($P(x|y)$ non cambia), ma la prevalenza complessiva della malattia nella popolazione $P(y)$ fluttua nel tempo (ad esempio, a causa di un'improvvisa epidemia o di una campagna vaccinale).

1.2.3 Concept Shift (o Concept Drift)

Il concept shift (o concept drift) si verifica quando cambia la relazione funzionale o semantica tra le feature di input e la variabile target, modificando di fatto la definizione stessa della classe da apprendere. Rappresenta la sfida più complessa, poiché i criteri decisionali appresi dal modello durante l'addestramento non sono più validi nell'ambiente operativo. Formalmente:

Definizione 4 (Concept shift). *Si verifica nel caso in cui:*

$$\begin{aligned} P_{tr}(y|x) \neq P_{tst}(y|x) \quad e \quad P_{tr}(x) = P_{tst}(x) \quad & (\text{nei problemi } X \rightarrow Y) \\ P_{tr}(x|y) \neq P_{tst}(x|y) \quad e \quad P_{tr}(y) = P_{tst}(y) \quad & (\text{nei problemi } Y \rightarrow X) \end{aligned}$$

Ad esempio, nei sistemi di filtraggio dello spam o di rilevamento delle intrusioni di rete, gli utenti malintenzionati modificano attivamente le proprie strategie per eludere i filtri esistenti, cambiando la definizione di ciò che costituisce un'e-mail di spam o un attacco, lasciando però apparentemente inalterata la struttura generale del traffico dati.

1.3 Cause del drift

Si possono rilevare due principali cause del data drift:

- **Sample Selection Bias:** Avviene quando il metodo di campionamento o di etichettatura dei dati di addestramento non è uniforme o casuale rispetto alla popolazione reale.
- **Ambienti Non Stazionari :** Molti contesti operativi sono intrinsecamente dinamici nel tempo e nello spazio. In generale, gli ambienti sono dinamici e, talvolta, la difficoltà nel far corrispondere lo scenario di apprendimento all'utilizzo nel mondo reale è dovuta proprio a questi cambiamenti. Tali scenari rendono complesso valutare l'adeguatezza di uno specifico modello in presenza di variazioni ambientali, aumentando così la probabilità di shift.

Capitolo 2

Analisi dei dataset

Per valutare e quantificare la capacità di generalizzazione Out-of-Distribution (OOD) del modello analizzato in questo progetto, abbiamo strutturato i test utilizzando tre dataset della famiglia ImageNet. In particolare, abbiamo utilizzato i dataset ImageNet-1k, ImageNet-C e ImageNet-R. In questo capitolo, descriveremo le caratteristiche principali di ciascun dataset e le motivazioni che ci hanno portato a sceglierli per i nostri test.

2.1 ImageNet

ImageNet è un ampio dataset d'immagini etichettate, ampiamente utilizzato per addestrare e valutare modelli di visione artificiale. Contiene oltre 14 milioni d'immagini annotate con più di 20.000 categorie di oggetti. La costruzione del dataset è stata effettuata in tre fasi:

1. **Mappatura WordNet:** per strutturare il dataset è stata usata la struttura gerarchica di WordNet, un database lessicale che organizza le parole in insiemi di sinonimi (synsets) e le collega tra loro attraverso relazioni semantiche. Ogni synset ha un "WordNet ID" (WNID) univoco, che è stato utilizzato per etichettare le immagini nel dataset. In questo modo, le immagini sono state organizzate in categorie gerarchiche basate sui synset di WordNet.
2. **Web scraping:** le immagini sono state raccolte da Internet utilizzando tecniche di web scraping. Sono stati utilizzati motori di ricerca e altre fonti online per raccogliere immagini pertinenti alle categorie di oggetti definite dai synset di WordNet.
3. **Annotazione manuale:** le immagini raccolte sono state annotate manualmente attraverso il servizio Amazon Mechanical Turk (AMTurk). Ogni immagine è stata etichettata con la categoria di oggetti corretta, garantendo così l'accuratezza delle annotazioni.

Il database completo originario è noto come ImageNet-21K (o ImageNet-22K) e contiene circa 14,2 milioni d'immagini distribuite su 21.841 classi gerarchiche. Non è presente uno split training-validation-test ufficiale. Il dataset non è bilanciato: alcune classi contengono un numero molto basso di esempi, mentre altre classi contengono un numero elevato di esempi.

2.2 ImageNet-1k

Vengono spesso utilizzati subset di ImageNet-21k per vari scopi. Uno dei più noti è ImageNet-1k, che contiene 1.000 classi di oggetti selezionate da ImageNet-21k. Il dataset contiene 1.281.167 immagini di training, 50.000 immagini (50 per classe) di validation e 100.000 immagini di test.

Questo dataset è stato utilizzato per addestrare e valutare modelli di visione artificiale, in particolare per la competizione ImageNet Large Scale Visual Recognition Challenge (ILSVRC). Per questo motivo, il test set non è etichettato, in quanto serve unicamente a valutare le prestazioni dei modelli durante la competizione. Perciò, per i nostri test, abbiamo utilizzato il validation set come test set, questo è possibile in quanto il validation set non viene utilizzato per l'addestramento del modello, ma solo per la valutazione delle sue prestazioni[1].

A differenza della struttura gerarchica ad albero di ImageNet-21K (che include macro-classi come "mammifero" o "veicolo"), ImageNet-1K contiene esclusivamente 1.000 classi non sovrapposte poste alla

base dell'albero gerarchico (es. singole razze di cani come "German shepherd", senza includere la classe genitore "dog")

2.3 ImageNet-C

A differenza di altri dataset, ImageNet-C non è stato raccolto fotografando nuovi oggetti o raschiando il web. È stato costruito applicando sistematicamente corruzioni digitali e matematiche direttamente sul set di validazione originale di ImageNet-1K (le 50.000 immagini di validazione). L'obiettivo dei creatori era imitare le reali limitazioni fisiche dei sensori delle fotocamere, le variazioni atmosferiche ambientali e i disturbi dovuti alla compressione e trasmissione dei dati, escludendo però alterazioni avversariali mirate (worst-case)[2]. Il dataset si sviluppa in modo gerarchico:

- **Corruzioni:** sono state applicate 15 corruzioni digitali e matematiche, suddivise in 4 categorie principali: *blur*, *noise*, *digital* e *weather*.
 - *Blur*: motion blur, defocus blur, frosted glass blur, gaussian blur, zoom blur
 - *Noise*: gaussian noise, shot noise, impulse noise
 - *Digital*: brightness, contrast, elastic transform, pixelate, jpeg compression
 - *Weather*: snow, frost, fog
- **Intensità:** per ogni corruzione sono stati generati 5 livelli di intensità, da 1 (minima) a 5 (massima).

La dimensione totale del test set di ImageNet-C è quindi di $50.000 \times 15 \text{ corruzioni} \times 5 \text{ severità} = 3.750.000$ immagini di test.




Figura 2.1: Esempi di corruzioni applicate a un'immagine del dataset ImageNet-1K.

Capitolo 3

Introduzione al modello

Capitolo 4

Analisi dei risultati

Bibliografia

- [1] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). ISSN: 1063-6919. Giu. 2016, pp. 770–778. DOI: 10.1109/CVPR.2016.90. URL: <https://ieeexplore.ieee.org/abstract/document/7780459> (visitato il giorno 22/08/2026).
- [2] Dan Hendrycks e Thomas G. Dietterich. *Benchmarking Neural Network Robustness to Common Corruptions and Surface Variations*. 27 Apr. 2019. DOI: 10.48550/arXiv.1807.01697. arXiv: 1807.01697[cs.LG]. URL: <http://arxiv.org/abs/1807.01697> (visitato il giorno 24/08/2026).
- [3] Jose G. Moreno-Torres et al. “A unifying view on dataset shift in classification”. In: *Pattern Recognition* 45.1 (1 gen. 2012), pp. 521–530. ISSN: 0031-3203. DOI: 10.1016/j.patcog.2011.06.019. URL: <https://www.sciencedirect.com/science/article/pii/S0031320311002901> (visitato il giorno 22/08/2026).
- [4] Lakpa Tamang et al. “Handling Out-of-Distribution Data: A Survey”. In: *IEEE Transactions on Knowledge and Data Engineering* 37.10 (ott. 2025), pp. 5948–5966. ISSN: 1558-2191. DOI: 10.1109/TKDE.2025.3592614. URL: <https://ieeexplore.ieee.org/document/11098614/> (visitato il giorno 22/08/2026).