

Report progetto Architetture Dati: data drift su ImageNet

Daniele Besozzi 894998, Andrea Consonni 900116, Elena Zen 895355

Indice

1	Introduzione al problema	2
1.1	Definizioni di data drift	2
1.2	Tipologie di data drift	3
1.2.1	Covariate shift (o Population Drift)	3
1.2.2	Prior probability shift	3
1.2.3	Concept Shift (o Concept Drift)	4
1.3	Cause del drift	4
2	Analisi dei dataset	5
2.1	ImageNet	5
2.2	ImageNet-1k	5
2.3	ImageNet-C	6
2.4	ImageNet-R	7
3	Introduzione al modello	9
3.1	Reti neurali convolutive	9
3.2	Reti residuali	10
3.2.1	ResNet50	10
4	Presentazione della metodologia	11
4.1	Librerie e strumenti utilizzati	11
4.2	Preprocessing dei dataset	11
4.3	Estrazioni delle feature e inferenza del modello	12
4.4	Pipeline di testing e calcolo delle metriche	12
4.5	Analisi del drift	13
4.6	Analisi delle metriche di performance	13
5	Analisi dei risultati	14
5.1	Analisi delle metriche di drift sui dataset	14
5.1.1	ImageNet-1k vs ImageNet-R	14
5.1.2	ImageNet-1k vs ImageNet-C	14
5.2	Analisi delle metriche di drift sulle feature del modello	38
5.2.1	ImageNet-1k vs ImageNet-R	39
5.2.2	ImageNet-1k vs ImageNet-C	39
5.3	Analisi delle performance del modello	41
5.3.1	ImageNet-1k vs ImageNet-R	41
5.3.2	ImageNet-1k vs ImageNet-C	41

Capitolo 1

Introduzione al problema

I sistemi di Machine Learning vengono generalmente sviluppati assumendo che i dati osservati durante l'addestramento siano rappresentativi di quelli che il modello incontrerà durante il suo utilizzo. Nelle applicazioni reali, tuttavia, questa assunzione è spesso disattesa: le caratteristiche della distribuzione dei dati possono variare nel tempo o tra differenti contesti di utilizzo. Questo fenomeno, comunemente indicato come **data drift** o **distribution shift**, può determinare una significativa riduzione delle prestazioni del modello anche in assenza di modifiche alla sua architettura o ai suoi parametri.

Lo studio della robustezza rispetto al **data drift** rappresenta pertanto un aspetto fondamentale nella valutazione di sistemi di Machine Learning. È infatti importante non limitarsi a misurare le prestazioni su dati provenienti dalla stessa distribuzione utilizzata in fase di training (**in-distribution**), ma valutare anche il comportamento del modello in presenza di variazioni nella distribuzione degli input (**out-of-distribution**). Tali variazioni possono assumere forme differenti, includendo cambiamenti nelle condizioni di acquisizione delle immagini, nella loro qualità, nello stile visivo o nella presenza di specifiche perturbazioni.

In questo progetto, l'effetto del **data drift** sulle prestazioni dei modelli di classificazione d'immagini è stato analizzato attraverso una serie di benchmark basati sulla famiglia di dataset ImageNet. In particolare, sono stati considerati **ImageNet**, utilizzato come riferimento per la valutazione **in-distribution**, **ImageNet-R**, progettato per valutare la robustezza del modello rispetto a variazioni nella rappresentazione visiva degli oggetti, e **ImageNet-C**, che introduce diverse tipologie di corruzioni comuni applicate alle immagini. La combinazione di questi benchmark consente di analizzare il comportamento del modello in presenza di forme differenti di **distribution shift**, distinguendo tra variazioni di stile e rappresentazione e perturbazioni che simulano degradazioni o condizioni avverse nell'acquisizione dei dati.

L'obiettivo dell'analisi è quindi quantificare quanto il cambiamento nella distribuzione degli input influenzi le prestazioni del modello rispetto allo scenario di riferimento.

1.1 Definizioni di data drift

Nel machine learning supervisionato applicato a scenari reali, l'assunzione fondamentale per garantire la capacità di generalizzazione di un modello è che i dati di addestramento e i dati su cui il modello opererà una volta rilasciato siano indipendenti e identicamente distribuiti (i.i.d.) [1, 2]. Tuttavia, negli scenari applicativi reali, questa assunzione teorica viene costantemente violata. Le discrepanze tra l'ambiente controllato di laboratorio e le condizioni dinamiche del mondo reale, indotte da fattori quali distorsioni nella raccolta dei dati (sample selection bias), ambienti non stazionari o evoluzioni temporali e spaziali, causano variazioni nelle distribuzioni dei dati.

La letteratura scientifica ha storicamente sofferto di una frammentazione terminologica, utilizzando in modo intercambiabile nomi diversi per definire concetti analoghi (es. concept drift, population drift, changing environments, data fracture) [1]. In questo progetto adottiamo la seguente definizioni proposte da Moreno-Torres et al. [1]:

Definizione 1 (Dataset shift). *Si verifica quando la distribuzione di probabilità congiunta delle feature (o covariate) x e della variabile target (classe) y differisce tra la fase di addestramento (P_{tr}) e la fase di test (P_{tst}). Formalmente, $P_{tr}(y, x) \neq P_{tst}(y, x)$.*

Per poter analizzare e risolvere questo problema, è necessario distinguere la direzione causale tra la classe y e le feature x . Si identificano quindi due classi di problemi:

- Problemi $X \rightarrow Y$, in cui la classe y è determinata causalmente dal valore delle feature x (es. la rilevazione delle frodi bancarie, dove il comportamento dell'utente determina se c'è una frode).
- Problemi $Y \rightarrow X$, in cui la classe y determina causalmente il valore delle feature x (tipico della diagnostica medica, in cui la patologia y causa i sintomi osservabili x)

1.2 Tipologie di data drift

Il data drift può manifestarsi in diverse forme, a seconda della natura delle variazioni nella distribuzione dei dati. In questa sezione presentiamo le principali tipologie di data drift identificate in letteratura.

1.2.1 Covariate shift (o Population Drift)

Il covariate shift si riferisce al cambiamento della distribuzione delle variabili di input (o covariate) x tra la fase di training e quella di test, mentre la relazione condizionata che mappa l'input alla classe rimane del tutto invariata. Formalmente:

Definizione 2 (Covariate shift). *Appare solamente nei problemi del tipo $X \rightarrow Y$ e si verifica nel caso in cui $P_{tr}(x) \neq P_{tst}(x)$ e $P_{tr}(y|x) = P_{tst}(y|x)$*

Ad esempio, un modello di classificazione d'immagini addestrato principalmente su foto di cani su uno sfondo erboso che viene poi testato su immagini di cani che indossano impermeabili in contesti urbani [2]. Le feature visive di sfondo e i dettagli superficiali cambiano ($P(x)$ muta), ma il concetto semantico di "cane" associato a quelle immagini rimane lo stesso ($P(y|x)$ è costante).



Figura 1.1: Esempio di covariate shift

1.2.2 Prior probability shift

Il prior probability shift rappresenta il caso duale del covariate shift, focalizzato sul cambiamento della distribuzione della variabile target y , mentre la distribuzione condizionata delle feature data la classe rimane costante. Formalmente:

Definizione 3 (Prior probability shift). *Appare solamente nei problemi del tipo $Y \rightarrow X$ e si verifica nel caso in cui $P_{tr}(y) \neq P_{tst}(y)$ e $P_{tr}(x|y) = P_{tst}(x|y)$.*

Ad esempio, in un sistema di diagnostica medica per una specifica malattia infettiva, la distribuzione dei sintomi per i soggetti malati e sani rimane costante ($P(x|y)$ non cambia), ma la prevalenza complessiva della malattia nella popolazione $P(y)$ fluttua nel tempo (ad esempio, a causa di un'improvvisa epidemia o di una campagna vaccinale).

1.2.3 Concept Shift (o Concept Drift)

Il concept shift (o concept drift) si verifica quando cambia la relazione funzionale o semantica tra le feature di input e la variabile target, modificando di fatto la definizione stessa della classe da apprendere. Rappresenta la sfida più complessa, poiché i criteri decisionali appresi dal modello durante l'addestramento non sono più validi nell'ambiente operativo. Formalmente:

Definizione 4 (Concept shift). *Si verifica nel caso in cui:*

$$\begin{aligned} P_{tr}(y|x) \neq P_{tst}(y|x) \quad e \quad P_{tr}(x) = P_{tst}(x) \quad & (\text{nei problemi } X \rightarrow Y) \\ P_{tr}(x|y) \neq P_{tst}(x|y) \quad e \quad P_{tr}(y) = P_{tst}(y) \quad & (\text{nei problemi } Y \rightarrow X) \end{aligned}$$

Ad esempio, nei sistemi di filtraggio dello spam o di rilevamento delle intrusioni di rete, gli utenti malintenzionati modificano attivamente le proprie strategie per eludere i filtri esistenti, cambiando la definizione di ciò che costituisce un'e-mail di spam o un attacco, lasciando però apparentemente inalterata la struttura generale del traffico dati.

1.3 Cause del drift

Si possono rilevare due principali cause del data drift:

- **Sample Selection Bias:** Avviene quando il metodo di campionamento o di etichettatura dei dati di addestramento non è uniforme o casuale rispetto alla popolazione reale.
- **Ambienti Non Stazionari :** Molti contesti operativi sono intrinsecamente dinamici nel tempo e nello spazio. In generale, gli ambienti sono dinamici e, talvolta, la difficoltà nel far corrispondere lo scenario di apprendimento all'utilizzo nel mondo reale è dovuta proprio a questi cambiamenti. Tali scenari rendono complesso valutare l'adeguatezza di uno specifico modello in presenza di variazioni ambientali, aumentando così la probabilità di shift.

Capitolo 2

Analisi dei dataset

Per valutare e quantificare la capacità di generalizzazione Out-of-Distribution (OOD) del modello analizzato in questo progetto, abbiamo strutturato i test utilizzando tre dataset della famiglia ImageNet. In particolare, abbiamo utilizzato i dataset ImageNet-1k, ImageNet-C e ImageNet-R. In questo capitolo, descriveremo le caratteristiche principali di ciascun dataset e le motivazioni che ci hanno portato a sceglierli per i nostri test.

2.1 ImageNet

ImageNet è un ampio dataset d'immagini etichettate, ampiamente utilizzato per addestrare e valutare modelli di visione artificiale. La versione originale di Imagenet viene chiamata ImageNet-21K (o ImageNet-22K) e contiene circa 14,2 milioni d'immagini distribuite su 21.841 classi gerarchiche. La costruzione del dataset è stata effettuata in tre fasi:

1. **Mappatura WordNet:** per strutturare il dataset è stata usata la struttura gerarchica di WordNet, un database lessicale che organizza le parole in insiemi di sinonimi (synsets) e le collega tra loro attraverso relazioni semantiche. Ogni synset ha un "WordNet ID" (WNID) univoco, che è stato utilizzato per etichettare le immagini nel dataset. In questo modo, le immagini sono state organizzate in categorie gerarchiche basate sui synset di WordNet. La tassonomia si sviluppa su 9 livelli gerarchici, partendo da concetti astratti di alto livello (es. level 1: mammal) fino a classi estremamente specifiche (es. level 9: German shepherd)
2. **Web scraping:** le immagini sono state raccolte da Internet utilizzando tecniche di web scraping. Sono stati utilizzati motori di ricerca e altre fonti online per raccogliere immagini pertinenti alle categorie di oggetti definite dai synset di WordNet.
3. **Annotazione manuale:** le immagini raccolte sono state annotate manualmente attraverso il servizio Amazon Mechanical Turk (AMTurk). Ogni immagine è stata etichettata con la categoria di oggetti corretta, garantendo così l'accuratezza delle annotazioni. 49.000 lavoratori provenienti da 167 paesi hanno validato e filtrato oltre 160 milioni d'immagini candidate.

Non è presente uno split training-validation-test ufficiale. Il dataset non è bilanciato: alcune classi contengono un numero molto basso di esempi, mentre altre classi contengono un numero elevato di esempi.

2.2 ImageNet-1k

Vengono spesso utilizzati subset di ImageNet-21k per vari scopi. Uno dei più noti è ImageNet-1k, che contiene 1.000 classi di oggetti selezionate da ImageNet-21k. Il dataset contiene 1.281.167 immagini di training, 50.000 immagini (50 per classe) di validation e 100.000 immagini di test.

Questo dataset è stato utilizzato per addestrare e valutare modelli di visione artificiale, in particolare per la competizione ImageNet Large Scale Visual Recognition Challenge (ILSVRC). Per questo motivo, il test set non è etichettato, in quanto serve unicamente a valutare le prestazioni dei modelli durante la competizione. Perciò, per i nostri test, abbiamo utilizzato il validation set come test set, questo è

possibile in quanto il validation set non viene utilizzato per l'addestramento del modello, ma solo per la valutazione delle sue prestazioni[3].

A differenza della struttura gerarchica ad albero di ImageNet-21K (che include macro-classi come "mammifero" o "veicolo"), ImageNet-1K contiene esclusivamente 1.000 classi non sovrapposte poste alla base dell'albero gerarchico (es. singole razze di cani come "German shepherd", senza includere la classe genitore "dog")

2.3 ImageNet-C

A differenza di altri dataset, ImageNet-C non è stato raccolto fotografando nuovi oggetti o facendo web scraping. È stato costruito applicando sistematicamente corruzioni digitali e matematiche direttamente sul set di validazione originale di ImageNet-1K (le 50.000 immagini di validazione). L'obiettivo dei creatori era imitare le reali limitazioni fisiche dei sensori delle fotocamere, le variazioni atmosferiche ambientali e i disturbi dovuti alla compressione e trasmissione dei dati, escludendo però alterazioni avversariali mirate (worst-case)[4]. Il dataset si sviluppa in modo gerarchico:

- **Corruzioni:** sono state applicate 15 corruzioni digitali e matematiche, suddivise in 4 categorie principali: *blur*, *noise*, *digital* e *weather*.
 - *Blur*:
 - * Defocus Blur: Si verifica quando l'obiettivo della fotocamera è fuori fuoco rispetto al soggetto.
 - * Frosted Glass Blur: Riproduce la diffrazione della luce che attraversa pannelli o finestre di vetro satinato.
 - * Motion Blur: Sfocatura da movimento dovuta allo spostamento rapido della fotocamera durante il tempo di esposizione.
 - * Zoom Blur: Sfocatura radiale causata dal rapido avvicinamento fisico (o variazione di focale) verso l'oggetto.
 - *Noise*:
 - * Gaussian Noise: Simula il rumore termico e di bassa luminosità tipico dei sensori fisici.
 - * Shot Noise (Poisson Noise): Rumore elettronico causato dalla natura discreta della luce stessa durante l'acquisizione dei fotoni.
 - * Impulse Noise: Equivalente a colori del rumore "sale e pepe", causato da errori di trasmissione dei bit nei canali digitali.
 - *Digital*:
 - * Contrast: Modifica l'intervallo dinamico dei colori, simulando condizioni di luce estrema o scarsa riflettanza dei materiali.
 - * Elastic Transformations: Deforma localmente l'immagine stirando o contraendo piccole aree di pixel, simulando distorsioni ottiche della lente.
 - * Pixelation: Riproduce la perdita di dettagli ad alta frequenza che si verifica quando un'immagine a bassissima risoluzione viene ingrandita.
 - * JPEG: Introduce artefatti a blocchi e rumore ad alta frequenza tipici della compressione d'immagine lossy.
 - *Weather*:
 - * Snow: Simula la precipitazione nevosa, che introduce occlusioni e rifrazioni di luce complessa.
 - * Frost: Riproduce la formazione di cristalli di ghiaccio sulla superficie della lente o del sensore.
 - * Fog: Avvolge gli oggetti simulando la nebbia tramite l'algoritmo diamond-square, che assicura che ogni banco di nebbia generato sia unico per forma e densità su ciascuna immagine.
 - * Brightness: Simula le variazioni di intensità della luce solare diurna.
- **Intensità:** per ogni corruzione sono stati generati 5 livelli di intensità, da 1 (minima) a 5 (massima).

La dimensione totale del test set di ImageNet-C è quindi di $50.000 \times 15 \text{ corruzioni} \times 5 \text{ severità} = 3.750.000$ immagini di test.




Figura 2.1: Esempi di corruzioni applicate a un'immagine del dataset ImageNet-1K.

2.4 ImageNet-R

ImageNet-R è un dataset di immagini raccolte da Internet, progettato per testare la capacità di generalizzazione dei modelli di visione artificiale su immagini stilizzate e artistiche. Il dataset è stato creato seguendo le seguenti procedure descritte in [5]:

1. **Sottocampionamento delle classi:** Gli autori hanno selezionato un subset di 200 classi di ImageNet-1K. Ciò è stato necessario a causa della difficoltà di trovare immagini stilizzate per tutte le 1.000 classi di ImageNet-1K, dunque sono state selezionate solo le classi per le quali era possibile reperire un numero sufficiente d'immagini stilizzate. Inoltre sono state scelte classi facilmente riconoscibili da un umano, ad esempio "cane" invece che indicare una razza specifica di cane.
2. **Raccolta delle immagini:** Le immagini sono state ottenute tramite scraping da Flickr, fonte da cui erano state ottenute parte delle immagini di ImageNet-1K.
3. **Etichettatura:** Le immagini sono state etichettate associando il nome dell'oggetto a termini relativi a stili e supporti artistici, come: "art", "cartoon", "graffiti", "embroidery", "graphics", "origami", "painting", "pattern", "plastic object", "plush object", "sculpture", "line drawing", "tattoo" e "toy".
4. **Filtro di qualità manuale:**
 - Gli annotatori di Amazon Mechanical Turk hanno filtrato i dati grezzi tramite un'interfaccia modificata ereditata dal progetto ImageNetV2. Ad esempio, dopo lo scraping della query "lighthouse cartoon", i lavoratori dovevano validare se l'immagine rappresentasse effettivamente una rendition corretta e non ambigua di un faro.
 - Per eliminare ogni residuo di rumore, studenti di dottorato hanno esaminato manualmente ogni singola immagine selezionata, escludendo quelle con etichette errate o che contenevano soggetti multipli appartenenti a classi diverse di ImageNet.

Il dataset finale contiene 30.000 immagini di test, con un numero variabile d'immagini per classe, da un minimo di 51 a un massimo di 430 immagini per classe, in media 150 immagini per classe. Le immagini sono categorizzate in base a diversi stili (es. Painting, Sculpture, Origami, Cartoon, Toy, Embroidery,

ecc.). Ai fini della classificazione, le etichette di destinazione rimangono quelle semantiche di ImageNet-1K.




Figura 2.2: Esempi di immagini stilizzate del dataset ImageNet-R. Painting, etc. sono stili di rappresentazione, non etichette.

Capitolo 3

Introduzione al modello

Ogni tipo di modello di machine learning supervisionato può riscontrare, quando si trova ad operare in contesti reali, un drift nelle distribuzioni dei dati osservati rispetto alla distribuzione osservata durante la fase di addestramento. In particolare, uno dei tipi di modello più diffuso per il riconoscimento delle immagini è quello che prende il nome di **rete neurale convolutiva** (Convolutional neural network, CNN). In questo capitolo, introdurremo il funzionamento delle CNN e descriveremo la variante utilizzata per questo progetto, le **reti neurali residueali**.

3.1 Reti neurali convolutive

Le **reti neurali convolutive** furono per la prima volta introdotte nella loro forma moderna nel 1989 da Le Cun et al [6], i quali svilupparono LeNet-5, una rete convolutiva in grado di classificare le cifre scritte a mano su dei fogli. La struttura particolare di questo tipo di reti le rende particolarmente efficaci nell'ambito del riconoscimento di immagini, poiché esse sono capaci di sfruttare le **caratteristiche spaziali dell'input**, come per esempio la correlazione spaziale tra pixel vicini. Questa caratteristica permette inoltre di **ridurre il numero di pesi necessari da imparare**, rendendo quindi la rete più efficiente. La figura 3.1 mostra l'architettura di LeNet-5 come esempio di rete neurale convolutiva. Oltre ai layer di input e di output, le reti neurali convolutive sono formate principalmente da tre tipi di strati [7]:

- Strati convolutivi
- Strati di pooling (o di subsampling)
- Strati completamente connessi

Strato di input

Come nelle reti neurali tradizionali, lo strato di input di una rete neurale convolutiva conterrà i valori delle istanze che verranno passate alla rete. In particolare per le immagini, essi sono i **valori numerici**




Figura 3.1: Architettura di LeNet-5. Da [8]

dei suoi pixel. Possiamo quindi vedere un'immagine come una matrice di dimensioni $W \times H \times C$, con W la larghezza dell'immagine, H l'altezza dell'immagine e C il numero di **canali colore** (per esempio, $C = 3$ se l'immagine ha canali colore RGB).

Strati convolutivi

Strati di pooling

Strati completamente connessi

Altri tipi di strati

3.2 Reti residuali

3.2.1 ResNet50

Capitolo 4

Presentazione della metodologia

In questa sezione descriviamo la metodologia adottata per valutare la capacità di generalizzazione Out-of-Distribution (OOD) del modello analizzato. Il processo si articola in tre fasi principali: preprocessing dei dataset, testing del modello e analisi del drift.

4.1 Librerie e strumenti utilizzati

Il progetto è stato sviluppato in Python 3.12 e fa uso delle seguenti librerie principali:

- **PyTorch (torch) e TorchVision:** per il caricamento del modello ResNet-50 pre-addestrato, la definizione della pipeline di preprocessing e l'esecuzione dell'inferenza sulle GPU.
- **HuggingFace Datasets:** per il caricamento, la trasformazione e la gestione efficiente dei dataset ImageNet-1k, ImageNet-R e ImageNet-C in formato Arrow, con supporto al parallelismo e alla serializzazione su disco.
- **NumPy e Pandas:** per la manipolazione numerica e tabulare dei dati, inclusa la gestione delle feature estratte e dei risultati delle metriche.
- **Scikit-learn:** per il calcolo delle metriche di classificazione (accuracy, balanced accuracy, precision, recall, F1-score, MCC, Cohen's Kappa).
- **SciPy:**
- **Matplotlib e Seaborn:** per la visualizzazione dei risultati, inclusi grafici KDE di distribuzione delle proprietà delle immagini, andamenti delle metriche al vari della severità delle corruzioni e diagrammi a barre per il confronto baseline vs drift.
- **Pillow (PIL):** per l'estrazione delle proprietà visive delle immagini (luminosità, contrasto RMS, nitidezza, rapporto d'aspetto, area, media dei canali RGB).
- **tqdm:** per le barre di progresso durante l'estrazione delle proprietà e l'esecuzione dell'inferenza.

4.2 Preprocessing dei dataset

Il preprocessing è gestito dallo script `data_preprocess/datasets_preprocess.py`, che orchestra il caricamento, la trasformazione e il salvataggio su disco dei tre dataset.

- **ImageNet-1k:** Il validation set (50.000 immagini) è stato scaricato tramite HuggingFace Datasets utilizzando il builder `parquet`, necessario poiché il builder ufficiale costringe il download dell'intero dataset mentre per il nostro progetto è sufficiente il subset di validazione. L'accesso al dataset è gated e richiede autenticazione via `huggingface_hub`.
 - **Confronto con ImageNet-R:** Il validation set è stato filtrato per contenere esclusivamente le 200 classi presenti in ImageNet-R, ottenendo un dataset di 10.000 immagini (50 per classe). Questo cross-filtering garantisce che il confronto tra baseline e drift avvenga sullo stesso spazio di classi.

- **Confronto con ImageNet-C:** Il validation set è stato mantenuto intatto, in quanto ImageNet-C è costruito applicando corruzioni direttamente sulle stesse immagini del validation set di ImageNet-1k.
- **ImageNet-R:** Il dataset è stato caricato dal repository HuggingFace `axiong/imagenet-r`. Il pre-processing consiste in:
 - La mappatura dei WNID (WordNet ID) delle immagini agli indici di classe di ImageNet-1k tramite il file di mapping `LOC_sysnet_mapping.txt`, che associa ciascun WNID a un indice numerico (0-999) e a una descrizione testuale.
 - Il capping a 50 esempi per classe tramite la funzione `cap_examples_per_class()`, per garantire un bilanciamento uniforme con il set di ImageNet-1k utilizzato come baseline.
- **ImageNet-C:** Il dataset è stato scaricato direttamente dal sito Zenodo, che mette a disposizione quattro archivi tar (`blur.tar`, `digital.tar`, `noise.tar`, `weather.tar`). Dopo l'estrazione, è stata costruita una struttura di dataset HuggingFace separata per ogni coppia (corruzione, severità), ad esempio `gaussian_noise_sev_1`, `gaussian_noise_sev_2`, ecc. Ciascun dataset contiene le colonne `image`, `wnid` e `label`, dove il `label` è stato assegnato tramite la stessa mappatura WNID-to-index usata per gli altri dataset. I dati sono stati salvati su disco in formato Arrow per un accesso efficiente.

4.3 Estrazioni delle feature e inferenza del modello

Il modello analizzato è ResNet-50 con pesi pre-addestrati su ImageNet-1k (variante `IMAGENET1K_V2`), caricato tramite TorchVision. Il modello è stato impostato in modalità `eval()` e non è stato sottoposto ad alcun fine-tuning: l'obiettivo è valutare la robustezza del modello così come è, senza addestramento aggiuntivo. La funzione `extract_resnet50_features()` esegue un forward pass manuale attraverso i layer convoluzionali di ResNet-50, estraendo sia le feature del penultimo layer (output di `avgpool`, vettori a 2048 dimensioni) sia i logits di classificazione prodotti dal layer fully-connected finale. Questa strategia permette di raccogliere le feature intermedie per le analisi di drift basate sulle rappresentazioni del modello, senza dover eseguire due forward pass separati.

4.4 Pipeline di testing e calcolo delle metriche

Il testing è eseguito dagli script `test_model_ImageNetC.py` e `test_model_ImageNetR.py`, che implementano una pipeline strutturata in più step.

- **Inferenza:** La funzione `run_inference()` esegue il forward pass del modello sul dataloader, raccogliendo le etichette vere, le predizioni top-1, le predizioni top-5 e, opzionalmente, le feature del penultimo layer. Il tutto avviene con decoratore `@torch.no_grad()` per ottimizzare l'uso della memoria.
- **Metriche di classificazione:** La funzione `compute_metrics()` calcola un set completo di 14 metriche per ogni run di inferenza:
 - Accuracy e top-5 accuracy
 - Balanced accuracy (media del recall per classe)
 - Precision, recall e F1-score in varianti macro, weighted e micro
 - Matthews Correlation Coefficient (MCC)
 - Cohen's Kappa

Valutazione ripetuta con intervalli di confidenza

Per ottenere stime robuste con intervalli di confidenza, per ciascuna delle 5 ripetizioni, viene eseguito un forward pass completo applicando una pipeline di augmentation stocastica prima del preprocessing del modello. Le augmentation utilizzate sono `RandomResizedCrop(224, scale=(0.9, 1.0))` e `ColorJitter(brightness=0.08, contrast=0.08, saturation=0.05, hue=0.02)`. Questa strategia cattura la variabilità completa introdotta dalle augmentation stocastiche.

La funzione `compute_metrics_ci()` aggrega i risultati delle 5 ripetizioni calcolando media, deviazione standard e intervalli di confidenza al 95% per ogni metrica.

Baseline

Per ImageNet-C, il validation set originale di ImageNet-1k (50.000 immagini, tutte le 1000 classi) è stato utilizzato come baseline. Per ImageNet-R, il set preprocessato di ImageNet-1k (10.000 immagini, 200 classi) è stato utilizzato come baseline.

4.5 Analisi del drift

L'analisi del drift è stata condotta su due livelli:

- Proprietà visive delle immagini.
- Feature estratte dal modello ResNet-50.

4.6 Analisi delle metriche di performance

L'analisi delle metriche è condotta nel notebook `metrics_analysis.ipynb`, che implementa funzioni per il confronto sistematico delle prestazioni del modello tra baseline e dataset OOD.

- **Confronto ImageNet-1k vs ImageNet-R:** Per ogni metrica, viene calcolato il delta (`baseline_mean - drift_mean`) con intervallo di confidenza al 95% stimato tramite bootstrap (5000 iterazioni) o test t di Welch. La significatività del delta è valutata verificando se lo zero è incluso nell'intervallo di confidenza.
- **Confronto ImageNet-1k vs ImageNet-C:** Per ogni tipo di corruzione e livello di severità, vengono calcolate le metriche con intervalli di confidenza. L'analisi include:
 - Plot delle metriche al variare della severità per ogni singola corruzione, con linea di baseline e bande di confidenza.
 - Plot delle metriche per categoria di corruzione (noise, blur, digital, weather), sovrapponendo le curve di tutte le corruzioni della stessa categoria.
 - Calcolo della degradazione normalizzata: $D_s = (Acc_{\text{clean}} - Acc_s) / Acc_{\text{clean}}$, dove Acc_{clean} è l'accuracy sul baseline e Acc_s l'accuracy a severità s .
 - Calcolo dell'AUC della robustezza: $AUC_{\text{rob}} = \frac{1}{5} \sum_{s=1}^5 Acc_s / Acc_{\text{clean}}$, che quantifica la capacità complessiva del modello di mantenere le prestazioni al variare della severità.
 - Calcolo della pendenza (*slope*) della degradazione tramite regressione lineare, che indica la velocità di deterioramento delle prestazioni all'aumentare della severità.
 - Calcolo dell' R^2 della regressione, che indica quanto la relazione tra severità e degradazione sia lineare.

Capitolo 5

Analisi dei risultati

In questo capitolo analizzeremo i risultati ottenuti dall'applicazione della metodologia proposta ai dataset considerati e ai risultati ottenuti dall'inferenza del modello. Verranno presentati i principali indicatori di performance, le metriche di valutazione del drift e le eventuali osservazioni emerse durante l'analisi dei dati.

5.1 Analisi delle metriche di drift sui dataset

Per analizzare l'avvenimento di un data drift rispetto ad imagenet-1k, ci avvarremo di un test statistico (Distanza di Wesserstein) sulle seguenti misure:

- Luminanza
- Contrasto
- Nitidezza (Sharpness)
- Media dei canali colore

5.1.1 ImageNet-1k vs ImageNet-R

Come si può evincere dal grafico in figura 5.1, la maggior parte delle feature presenta un drift rispetto alla distribuzione di riferimento (imagenet-1k) secondo la distanza di Wesserstein. In particolare, tutte le misure tranne sharpness presentano un drift significativo, con valori di distanza di Wesserstein superiori a 0.1. La misura di sharpness, invece, risulta essere più simile alla distribuzione di riferimento, con un valore di distanza di Wesserstein inferiore a 0.1. Possiamo inoltre osservare che la distribuzione di brightness presenta una distanza di Wesserstein molto maggiore dei canali colore. Questo potrebbe essere dovuto al fatto che essendo ImageNet-R formato da immagini artistiche, tra cui disegni è possibile che ci sia un maggior numero d'immagini con uno sfondo bianco, dunque una maggiore varianza nella luminosità.

5.1.2 ImageNet-1k vs ImageNet-C

Per quanto riguarda ImageNet-C, abbiamo osservato i risultati distinguendo le corruzioni per tipo di corruzione e severità (1-5).

Confronto delle distribuzioni delle feature: ImageNet-1k vs ImageNet-R
Drift quando WD ≥ 0.1




Figura 5.1: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-R.

corruption	feature	sev_1	sev_2	sev_3	sev_4	sev_5
gaussian_noise	brightness	0.072713	0.085192	0.112507	0.162998	0.251874
gaussian_noise	mean_blue	0.028428	0.040312	0.083820	0.159918	0.274003
gaussian_noise	mean_green	0.053796	0.065129	0.086815	0.128471	0.203225
gaussian_noise	mean_red	0.046630	0.043086	0.060681	0.122065	0.223818
gaussian_noise	rms_contrast	0.114575	0.126554	0.220013	0.380643	0.601419
gaussian_noise	sharpness	1.385858	2.396271	3.420685	4.200996	4.791838
impulse_noise	brightness	0.080418	0.103368	0.126473	0.189028	0.267379
impulse_noise	mean_blue	0.029314	0.061542	0.096882	0.185154	0.284710
impulse_noise	mean_green	0.058434	0.074756	0.091807	0.144506	0.209471
impulse_noise	mean_red	0.038153	0.044674	0.068579	0.144231	0.233162
impulse_noise	rms_contrast	0.116605	0.132207	0.172549	0.310412	0.488980
impulse_noise	sharpness	0.857158	1.551392	2.150133	3.356574	4.291620
shot_noise	brightness	0.073568	0.092625	0.129523	0.226492	0.337091
shot_noise	mean_blue	0.031541	0.028833	0.031633	0.075767	0.125525
shot_noise	mean_green	0.038060	0.035835	0.035784	0.056486	0.089558
shot_noise	mean_red	0.050125	0.043082	0.034105	0.055221	0.094603
shot_noise	rms_contrast	0.106031	0.139771	0.253508	0.506550	0.723193
shot_noise	sharpness	1.504179	2.558167	3.451343	4.334384	4.723952

Tabella 5.1: Distanza di Wesserstein tra le distribuzioni delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-C nel gruppo di corruzione noise.

Possiamo notare dai dati nella tabella 5.1.2 che per tutti i tipi di rumore le feature rms_contrast e sharpness driftano a tutti i livelli di severità, mentre le altre feature driftano solo a severità più alte. In particolare, la feature sharpness presenta un drift molto più marcato rispetto alle altre feature, con valori di distanza di Wesserstein che superano 4 per la severità 5. Questo, può essere casuato dal fatto che il rumore può coprire i "bordi" degli oggetti. Possiamo notare inoltre che mean_green e mean_red per shot_noise non driftano, mentre mean_blue drifta solo al livello di severity 5. Osservando la figura 5.2 possiamo notare che per noise la distanza nei canali colore non aumenta sempre all'aumentare della severità, questa diminuisce da severity 1 a severity 3. La distanza nelle altre feature aumenta invece sempre per tutti i rumori all'aumentare della severità.




Figura 5.2: Distanza di Wesserstein tra le distribuzioni delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-C nel gruppo di corruzione noise, al variare della severit .

corruption	feature	sev_1	sev_2	sev_3	sev_4	sev_5
defocus_blur	brightness	0.060605	0.060416	0.060385	0.050140	0.049462
defocus_blur	mean_blue	0.038377	0.038431	0.038553	0.038591	0.038571
defocus_blur	mean_green	0.040674	0.040607	0.040626	0.040581	0.040763
defocus_blur	mean_red	0.059018	0.059035	0.059161	0.059179	0.059252
defocus_blur	rms_contrast	0.417192	0.486428	0.606822	0.669142	0.772384
defocus_blur	sharpness	1.265309	1.283204	1.292588	1.292072	1.294569
glass_blur	brightness	0.064491	0.064835	0.062973	0.063866	0.063666
glass_blur	mean_blue	0.040414	0.041017	0.039830	0.040450	0.040463
glass_blur	mean_green	0.040329	0.040112	0.039959	0.039883	0.039657
glass_blur	mean_red	0.060777	0.061247	0.060013	0.060569	0.060458
glass_blur	rms_contrast	0.350142	0.423292	0.497461	0.569429	0.691295
glass_blur	sharpness	1.158576	1.232642	1.238898	1.258086	1.286698
motion_blur	brightness	0.056901	0.056778	0.056420	0.055830	0.054923
motion_blur	mean_blue	0.034105	0.034367	0.034439	0.034397	0.034168
motion_blur	mean_green	0.041566	0.041327	0.041100	0.040844	0.040585
motion_blur	mean_red	0.055418	0.055543	0.055489	0.055315	0.054954
motion_blur	rms_contrast	0.344950	0.438142	0.551789	0.662401	0.744262
motion_blur	sharpness	1.041598	1.140697	1.199950	1.232650	1.247467
zoom_blur	brightness	0.066676	0.068524	0.070336	0.071692	0.073191
zoom_blur	mean_blue	0.043693	0.045843	0.047872	0.049723	0.051801
zoom_blur	mean_green	0.049571	0.052709	0.055854	0.058789	0.062629
zoom_blur	mean_red	0.068991	0.072782	0.076475	0.079874	0.083973
zoom_blur	rms_contrast	0.458881	0.526616	0.611801	0.661374	0.740796
zoom_blur	sharpness	1.165725	1.206743	1.218080	1.235984	1.237147

Tabella 5.2: Distanza di Wesserstein tra le distribuzioni delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-C nel gruppo di corruzione blur.

Possiamo notare dai dati in tabella 5.1.2 che per tutti i tipi di blur la brightness e i canali colore non driftano, questo accade perché i blur non modificano la luminosità o i colori delle immagini. Le feature rms_contrast e sharpness driftano a tutti i livelli di severità. In particolare, la feature sharpness presenta un drift molto più marcato rispetto alle altre feature, con valori di distanza di Wesserstein che superano 1.2 per la severità 5. Questo, può essere causato dal fatto che il blur può coprire i "bordi" degli oggetti, diminuendo la nitidezza e il contrasto, come si può osservare ad esempio nella figura 5.12.




Figura 5.3: Distanza di Wesserstein tra le distribuzioni delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-C nel gruppo di corruzione blur, al variare della severit .

corruption	feature	sev_1	sev_2	sev_3	sev_4	sev_5
brightness	brightness	0.576325	1.128612	1.609895	2.022776	2.348483
brightness	mean_blue	0.037699	0.043582	0.047753	0.053588	0.056299
brightness	mean_green	0.039589	0.040811	0.042565	0.052990	0.059364
brightness	mean_red	0.057856	0.063008	0.064307	0.068695	0.069323
brightness	rms_contrast	0.194603	0.343004	0.586194	0.913852	1.269411
brightness	sharpness	0.239242	0.248618	0.285387	0.348412	0.429741
fog	brightness	0.337783	0.344840	0.364152	0.401109	0.441012
fog	mean_blue	0.525600	0.576151	0.612098	0.613082	0.639908
fog	mean_green	0.380592	0.415061	0.439368	0.440063	0.458478
fog	mean_red	0.457440	0.503187	0.535868	0.536735	0.561158
fog	rms_contrast	1.694664	1.723715	1.590665	1.471921	1.383768
fog	sharpness	1.103313	1.169476	1.208260	1.207460	1.229185
frost	brightness	1.681603	1.974560	2.112238	1.987928	2.055561
frost	mean_blue	0.469288	0.643080	0.722371	0.743677	0.783210
frost	mean_green	0.212773	0.240710	0.249700	0.248716	0.254829
frost	mean_red	0.436628	0.609805	0.691184	0.713028	0.753416
frost	rms_contrast	0.537042	1.067577	1.318931	1.377810	1.495522
frost	sharpness	0.285483	0.293777	0.247972	0.242873	0.210797
snow	brightness	1.146456	1.850992	1.839177	2.211917	2.592699
snow	mean_blue	0.373648	0.528322	0.529197	0.599734	0.670009
snow	mean_green	0.269782	0.371856	0.373095	0.420665	0.467768
snow	mean_red	0.322548	0.463436	0.463859	0.526932	0.588320
snow	rms_contrast	0.099864	0.189850	0.176810	0.226027	0.652584
snow	sharpness	0.461836	1.037702	0.549788	0.515835	0.599181

Tabella 5.3: Distanza di Wesserstein tra le distribuzioni delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-C nel gruppo di corruzione weather.

Drift (Wasserstein) vs severità — categoria: weather




Figura 5.4: Distanza di Wesserstein tra le distribuzioni delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-C nel gruppo di corruzione weather, al variare della severità.

corruption	feature	sev_1	sev_2	sev_3	sev_4	sev_5
contrast	brightness	0.060245	0.060239	0.060229	0.060227	0.060195
contrast	mean_blue	0.038418	0.038245	0.037904	0.037598	0.037547
contrast	mean_green	0.041440	0.041902	0.042790	0.043391	0.043403
contrast	mean_red	0.059435	0.059512	0.059563	0.059451	0.059261
contrast	rms_contrast	2.330083	2.691652	3.053031	3.413698	3.593123
contrast	sharpness	1.112014	1.212285	1.281598	1.318082	1.325120
elastic_transform	brightness	0.051794	0.044459	0.059603	0.059610	0.059654
elastic_transform	mean_blue	0.039154	0.042950	0.036830	0.036657	0.036251
elastic_transform	mean_green	0.043501	0.049631	0.041769	0.041790	0.042117
elastic_transform	mean_red	0.061286	0.067652	0.058096	0.057926	0.057702
elastic_transform	rms_contrast	0.269896	0.304468	0.249420	0.249590	0.249708
elastic_transform	sharpness	0.862587	0.768063	0.821826	0.774113	0.614177
jpeg_compression	brightness	0.057809	0.057875	0.058283	0.058583	0.057985
jpeg_compression	mean_blue	0.022065	0.026881	0.018877	0.021624	0.023145
jpeg_compression	mean_green	0.060105	0.051337	0.057659	0.054069	0.058407
jpeg_compression	mean_red	0.052134	0.051353	0.046059	0.043821	0.035850
jpeg_compression	rms_contrast	0.183292	0.187883	0.190634	0.196080	0.196912
jpeg_compression	sharpness	0.469067	0.514780	0.534496	0.564141	0.578935
pixelate	brightness	0.056300	0.056056	0.056462	0.056612	0.056343
pixelate	mean_blue	0.029980	0.029781	0.031634	0.032457	0.032972
pixelate	mean_green	0.043141	0.042790	0.042617	0.042332	0.041621
pixelate	mean_red	0.052299	0.051931	0.053595	0.054230	0.054373
pixelate	rms_contrast	0.223815	0.236370	0.276135	0.321615	0.353021
pixelate	sharpness	0.318243	0.342908	0.411007	0.488771	0.533425

Tabella 5.4: Distanza di Wesserstein tra le distribuzioni delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-C nel gruppo di corruzione digital.

Drift (Wasserstein) vs severità — categoria: digital




Figura 5.5: Distanza di Wesserstein tra le distribuzioni delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-C nel gruppo di corruzione digital, al variare della severità.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: gaussian_noise




Figura 5.6: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con rumore gaussiano.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: shot_noise




Figura 5.7: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con rumore di shot.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: impulse_noise




Figura 5.8: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con rumore impulsivo.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: defocus_blur




Figura 5.9: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con sfocatura da defocus.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: motion_blur




Figura 5.10: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con sfocatura da movimento.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: zoom_blur




Figura 5.11: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con sfocatura da zoom.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: glass_blur




Figura 5.12: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con corruzione da vetro satinato.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: frost




Figura 5.13: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con corruzione da brina.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: fog




Figura 5.14: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con corruzione da nebbia.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: snow




Figura 5.15: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con corruzione da neve.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: brightness




Figura 5.16: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con corruzione da luminosità.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: contrast




Figura 5.17: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con corruzione da contrasto.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: pixelate




Figura 5.18: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con corruzione da pixelizzazione.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: jpeg_compression




Figura 5.19: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con corruzione da compressione JPEG.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: elastic_transform




Figura 5.20: Distribuzione delle misure di luminanza, contrasto, nitidezza e media dei canali colore per ImageNet-1k e ImageNet-C con corruzione da trasformazione elastica.

5.2 Analisi delle metriche di drift sulle feature del modello

In questa sezione vengono analizzate le metriche di drift calcolate sulle feature del modello ResNet-50, estratte dal layer `avgpool1`. Per poter fare l'analisi di MMD delle feature, è stato necessario effettuare un campionamento a 10.000 esempi, in quanto utilizzare l'intero dataset avrebbe richiesto una quantità di memoria della GPU a noi non disponibile. Il campionamento è casuale, mantenendo un numero equo di esempi per ogni classe.

5.2.1 ImageNet-1k vs ImageNet-R

dataset	is_drift	p_val	distance
ImageNetR	True	0.0000	0.0805

Tabella 5.5: Risultati del test di MMD tra le feature estratte dal layer `avgpool` del modello ResNet-50 per ImageNet-1k e ImageNet-R.

5.2.2 ImageNet-1k vs ImageNet-C

corruption	severity	is_drift	p_val	distance
defocus_blur	1	True	0.0000	0.0002
defocus_blur	2	True	0.0000	0.0003
defocus_blur	3	True	0.0000	0.0005
defocus_blur	4	True	0.0000	0.0009
defocus_blur	5	True	0.0000	0.0022
glass_blur	1	True	0.0000	0.0002
glass_blur	2	True	0.0000	0.0031
glass_blur	3	True	0.0000	0.0176
glass_blur	4	True	0.0000	0.0321
glass_blur	5	True	0.0000	0.0238
motion_blur	1	False	0.2000	0.0000
motion_blur	2	False	0.1500	0.0001
motion_blur	3	True	0.0000	0.0013
motion_blur	4	True	0.0000	0.0099
motion_blur	5	True	0.0000	0.0229
zoom_blur	1	True	0.0000	0.0006
zoom_blur	2	True	0.0000	0.0021
zoom_blur	3	True	0.0000	0.0017
zoom_blur	4	True	0.0000	0.0027
zoom_blur	5	True	0.0000	0.0013

Tabella 5.6: Risultati del test di MMD tra le feature estratte dal layer `avgpool` del modello ResNet-50 per ImageNet-1k e ImageNet-C, corruzione di tipo blur.

corruption	severity	is_drift	p_val	distance
brightness	1	False	0.3500	0.0000
brightness	2	False	0.1000	0.0001
brightness	3	False	0.1000	0.0000
brightness	4	False	0.2500	0.0001
brightness	5	True	0.0000	0.0003
contrast	1	False	0.2500	0.0000
contrast	2	False	0.1500	0.0001
contrast	3	False	0.1500	0.0001
contrast	4	True	0.0000	0.0005
contrast	5	True	0.0000	0.0029
elastic_transform	1	False	0.2500	0.0001
elastic_transform	2	True	0.0000	0.0011
elastic_transform	3	True	0.0000	0.0017
elastic_transform	4	True	0.0000	0.0083
elastic_transform	5	True	0.0000	0.0740
jpeg_compression	1	False	0.0500	0.0001
jpeg_compression	2	False	0.1500	0.0001
jpeg_compression	3	False	0.1000	0.0002
jpeg_compression	4	False	0.0500	0.0002
jpeg_compression	5	False	0.0500	0.0002
pixelate	1	False	0.2000	0.0001
pixelate	2	True	0.0000	0.0002
pixelate	3	True	0.0000	0.0005
pixelate	4	True	0.0000	0.0020
pixelate	5	True	0.0000	0.0126

Tabella 5.7: Risultati del test di MMD tra le feature estratte dal layer `avgpool` del modello ResNet-50 per ImageNet-1k e ImageNet-C, corruzione di tipo digital.

corruption	severity	is_drift	p_val	distance
gaussian_noise	1	False	0.5000	0.0000
gaussian_noise	2	True	0.0000	0.0005
gaussian_noise	3	True	0.0000	0.0025
gaussian_noise	4	True	0.0000	0.0110
gaussian_noise	5	True	0.0000	0.0682
impulse_noise	1	True	0.0000	0.0004
impulse_noise	2	True	0.0000	0.0014
impulse_noise	3	True	0.0000	0.0040
impulse_noise	4	True	0.0000	0.0215
impulse_noise	5	True	0.0000	0.0840
shot_noise	1	False	0.2000	0.0000
shot_noise	2	True	0.0000	0.0005
shot_noise	3	True	0.0000	0.0028
shot_noise	4	True	0.0000	0.0155
shot_noise	5	True	0.0000	0.0433

Tabella 5.8: Risultati del test di MMD tra le feature estratte dal layer `avgpool` del modello ResNet-50 per ImageNet-1k e ImageNet-C, corruzione di tipo noise.

corruption	severity	is_drift	p_val	distance
fog	1	False	0.3500	0.0000
fog	2	False	0.1500	0.0001
fog	3	False	0.2500	0.0001
fog	4	False	0.1000	0.0002
fog	5	True	0.0000	0.0021
frost	1	False	0.1500	0.0000
frost	2	True	0.0000	0.0004
frost	3	True	0.0000	0.0016
frost	4	True	0.0000	0.0020
frost	5	True	0.0000	0.0043
snow	1	True	0.0000	0.0003
snow	2	True	0.0000	0.0010
snow	3	True	0.0000	0.0032
snow	4	True	0.0000	0.0050
snow	5	True	0.0000	0.0133

Tabella 5.9: Risultati del test di MMD tra le feature estratte dal layer `avgpool` del modello ResNet-50 per ImageNet-1k e ImageNet-C, corruzione di tipo weather.

5.3 Analisi delle performance del modello

In questa sezione vengono analizzate le performance del modello ResNet-50 su ImageNet-R e ImageNet-C. Per ImageNet-R, confronteremo le metriche ottenute dalla classificazione delle immagini del dataset con le metriche ottenute dalla classificazione delle immagini di ImageNet-1k. Per ImageNet-C, invece, analizzeremo l'accuracy del modello al variare della severità della corruzione, calcolando la degradazione delle performance rispetto alla severity, calcolando la robustezza del modello e misurando quanto linearmente la severità della corruzione influisca sulla degradazione delle performance del modello.

5.3.1 ImageNet-1k vs ImageNet-R

5.3.2 ImageNet-1k vs ImageNet-C

Bibliografia

- [1] Jose G. Moreno-Torres et al. «A unifying view on dataset shift in classification». In: *Pattern Recognition* 45.1 (1 gen. 2012), pp. 521–530. ISSN: 0031-3203. DOI: 10.1016/j.patcog.2011.06.019. URL: <https://www.sciencedirect.com/science/article/pii/S0031320311002901> (visitato il giorno 22/08/2026).
- [2] Lakpa Tamang et al. «Handling Out-of-Distribution Data: A Survey». In: *IEEE Transactions on Knowledge and Data Engineering* 37.10 (ott. 2025), pp. 5948–5966. ISSN: 1558-2191. DOI: 10.1109/TKDE.2025.3592614. URL: <https://ieeexplore.ieee.org/document/11098614/> (visitato il giorno 22/08/2026).
- [3] Kaiming He et al. «Deep Residual Learning for Image Recognition». In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). ISSN: 1063-6919. Giu. 2016, pp. 770–778. DOI: 10.1109/CVPR.2016.90. URL: <https://ieeexplore.ieee.org/abstract/document/7780459> (visitato il giorno 22/08/2026).
- [4] Dan Hendrycks e Thomas G. Dietterich. *Benchmarking Neural Network Robustness to Common Corruptions and Surface Variations*. 27 Apr. 2019. DOI: 10.48550/arXiv.1807.01697. arXiv: 1807.01697[cs.LG]. URL: <http://arxiv.org/abs/1807.01697> (visitato il giorno 24/08/2026).
- [5] Dan Hendrycks et al. «The Many Faces of Robustness: A Critical Analysis of Out-of-Distribution Generalization». In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021 IEEE/CVF International Conference on Computer Vision (ICCV). ISSN: 2380-7504. Ott. 2021, pp. 8320–8329. DOI: 10.1109/ICCV48922.2021.00823. URL: <https://ieeexplore.ieee.org/document/9710159/> (visitato il giorno 22/08/2026).
- [6] Yann LeCun et al. «Handwritten Digit Recognition with a Back-Propagation Network». In: *Advances in Neural Information Processing Systems*. Vol. 2. Morgan-Kaufmann, 1989. URL: https://proceedings.neurips.cc/paper_files/paper/1989/hash/53c3bce66e43be4f209556518c2fcb54-Abstract.html (visitato il giorno 04/09/2026).
- [7] Keiron O’Shea e Ryan Nash. *An Introduction to Convolutional Neural Networks*. arXiv.org. 26 Nov. 2015. URL: <https://arxiv.org/abs/1511.08458v2> (visitato il giorno 04/09/2026).
- [8] Jiuxiang Gu et al. «Recent advances in convolutional neural networks». In: *Pattern Recognition* 77 (mag. 2018), pp. 354–377. ISSN: 00313203. DOI: 10.1016/j.patcog.2017.10.013. URL: <https://linkinghub.elsevier.com/retrieve/pii/S0031320317304120> (visitato il giorno 04/09/2026).