

Report progetto Architetture Dati: data drift su ImageNet

Analisi delle prestazioni di ResNet-50 su ImageNet-R e ImageNet-C

Daniele Besozzi 894998, Andrea Consonni 900116, Elena Zen 895355

Progetto Architetture Dati

- 1 Introduzione al Data Drift
- 2 I Dataset
- 3 Il Modello: ResNet-50
- 4 Metodologia
- 5 Risultati: Misurazione del Drift
- 6 Risultati: Analisi delle Performance
- 7 Conclusioni e Sviluppi

Il problema del Data Drift

- **Assunzione classica (i.i.d.):** Nel machine learning si assume che i dati di test e di addestramento provengano dalla stessa distribuzione e che siano indipendenti.
- **Realtà operativa:** Spesso questa assunzione è disattesa. La distribuzione cambia nel tempo o nello spazio → **Data drift** o **Distribution shift**.
- **Conseguenza:** Calo significativo delle prestazioni del modello, anche senza alcuna modifica ai suoi pesi o all'architettura.
- **Obiettivo del progetto:** Quantificare l'effetto del drift sulle prestazioni dei modelli di classificazione d'immagini.

Secondo Moreno-Torres et al., possiamo definire il **Dataset Shift** come:

Dataset shift

Si verifica quando la distribuzione di probabilità congiunta delle feature x e della variabile target y differisce tra la fase di addestramento (P_{tr}) e la fase di test (P_{tst}).

Formalmente: $P_{tr}(y, x) \neq P_{tst}(y, x)$.

È essenziale distinguere la direzione causale:

- $X \rightarrow Y$: Le feature determinano la classe (es. frodi bancarie).
- $Y \rightarrow X$: La classe determina le feature (es. patologia che causa sintomi).

Covariate Shift (o Population Drift)

- Cambiano le feature in input, ma la classe semantica resta la stessa.
- $P_{tr}(x) \neq P_{tst}(x)$ e $P_{tr}(y|x) = P_{tst}(y|x)$.
- È la forma di drift indagata in questo progetto (variazioni di stile, perturbazioni visive).


dogs in water



cats in grass



dogs in grass



cats in water



Prior Probability Shift

Cambia la frequenza delle classi ($P(y)$ fluttua), ma la distribuzione delle feature data la classe resta uguale. Tipico della diagnostica (epidemie).

Concept Shift

Cambia la definizione stessa della classe da apprendere ($P_{tr}(y|x) \neq P_{tst}(y|x)$). Esempio: spammer che cambiano tattiche per ingannare i filtri.

Cause principali del drift:


- Sample Selection Bias (campionamento non uniforme).
- Ambienti Non Stazionari (dinamismo temporale e spaziale).

ImageNet-1k (La Baseline)

- Derivato dall'enorme ImageNet-21k (14.2M di immagini, mappatura su WordNet).
- **ImageNet-1k** contiene 1.000 classi specifiche poste alla base dell'albero gerarchico.
- Utilizzato originariamente per la competizione ILSVRC.
- **Nel progetto:** Utilizziamo il validation set di 50.000 immagini come benchmark **in-distribution** per stabilire le prestazioni ottimali del modello, ciò è possibile perché non è stato usato per fare fine tuning sui modelli.


ImageNet-C (Corruzioni)

- Costruito applicando sistematicamente **corruzioni digitali** sulle stesse 50.000 immagini del validation set di ImageNet-1k.
- Obiettivo: imitare limitazioni fisiche dei sensori, compressioni e variazioni atmosferiche.
- Struttura gerarchica:
 - 15 tipi di corruzioni in 4 categorie (*Blur*, *Noise*, *Digital*, *Weather*).
 - 5 livelli di intensità (severità).
- Totale: 3.750.000 immagini di test.




ImageNet-R (Rendition)

- Valuta il modello su **immagini stilizzate e artistiche**.
- Selezionato un subset di **200 classi** di ImageNet-1k, reperite via web scraping su Flickr.
- Immagini etichettate per stili: *art, cartoon, graffiti, painting, sculpture, toy, origami*, ecc.
- Filtro di qualità manuale tramite Amazon Mechanical Turk.
- Totale: ~ 30.000 immagini di test (media 150 per classe).



Reti Neurali Convulsive (CNN)

- Capaci di sfruttare le **caratteristiche spaziali** dell'input visivo (es. correlazione tra pixel vicini).
- **Vantaggio:** Riducono drasticamente i parametri rispetto a reti fully-connected usando filtri condivisi (*kernel*).
- Architettura base formata da: Strati Convolutivi, Strati di Pooling, Strati Fully-Connected.




Esempio storico: Architettura LeNet-5

Estrazione delle Feature Maps

Nei layer convolutivi, il kernel "scorre" sull'immagine estraendo caratteristiche.

- Un kernel mappa regioni locali.
- Viene applicata una funzione di attivazione non lineare.
- Layer profondi imparano feature sempre più complesse e astratte.





Il problema della degradazione e le ResNet


Problema: Aumentando i layer, l'accuratezza satura e poi decade (non a causa dell'overfitting).

Soluzione (Reti Residuali):

- Apprendimento residuale: impara il mapping $F(x) = H(x) - x$ invece di $H(x)$, dove $H(x)$ è il mapping desiderato.
- Uso di **Identity shortcut connections**: connessioni che saltano uno o più layer, facilitando l'ottimizzazione.



"Basic"
Residual block



"Bottleneck"
Residual block

- **Librerie:** Sviluppo in PyTorch, elaborazione dataset tramite HuggingFace e Arrow per l'efficienza. Evidenze di drift tramite Evidently (Wasserstein) e Alibi detect (MMD).
- **Filtro Dataset:** Per il test su ImageNet-R, ImageNet-1k è stato filtrato mantenendo solo le 200 classi in comune, per garantire un confronto paritario. Mentre ImageNet-R è stato tagliato a 50 immagini per classe.
- **Inferenza:** Uso di **ResNet-50** con pesi pre-addestrati (senza fine-tuning). Rilevate predizioni ed estratte le feature del penultimo layer (avgpool).
- **Metriche:** Calcolate Accuracy e top-5 Accuracy su 5 ripetizioni con *augmentation stocastica* per stimare gli Intervalli di Confidenza (Test t di Welch).

L'analisi del drift è stata condotta a due livelli:


- ① **Sulle proprietà visive:** Estrazione di Luminosità, Contrasto RMS, Nitidezza (Sharpness) e medie dei canali RGB (tramite PIL).
 - Misurato tramite **Distanza di Wasserstein** (soglia di drift: 0.1).
- ② **Sulle feature di rete:** Vettori a 2048 dimensioni estratti internamente dal modello.
 - Misurato tramite Test MMD (Maximum Mean Discrepancy, drift se $p\text{-value} < 0.05$).

Drift Visivo su ImageNet-R

La maggior parte delle feature presenta drift rispetto a ImageNet-1k.

- Drift significativo ovunque eccetto che per la *sharpness*.
- Alta varianza per la *brightness* (molte immagini artistiche hanno sfondi bianchi).

Confronto delle distribuzioni delle feature: ImageNet-1k vs ImageNet-R
Drift quando WD ≥ 0.1



Drift sulle Feature della Rete (MMD)


Anche internamente al modello, ImageNet-R genera un forte drift.

dataset	is_drift	p_val	distance
ImageNetR	True	0.0000	0.0805

- p-value pari a 0 (sotto la soglia 0.05).
- Coerente con il drift rilevato visivamente.

ImageNet-C: Drift Visivo - Categoria Blur


Valori della distanza di Wasserstein per le feature visive sulle corruzioni di tipo Blur (Motion, Zoom, Defocus, Glass, Frost).



ImageNet-C: Drift Visivo - Categoria Blur, esempio: Glass Blur


Distribuzioni Blur (es. *Glass Blur*):

- Luminosità e canali colore non presentano variazioni significative.
- Il contrasto e la nitidezza subiscono un forte slittamento a causa della fusione dei bordi.



ImageNet-C: Drift Visivo - Categoria Noise


Valori della distanza di Wasserstein per le feature visive sulle corruzioni di tipo Noise (Gaussian, Shot, Impulse).



ImageNet-C: Drift Visivo - Categoria Noise, esempio: Gaussian Noise


Distribuzioni Noise (es. *Gaussian*):

- Il rumore elettronico o termico altera pesantemente le alte frequenze.
- La *sharpness* schizza a valori elevatissimi (distanza di Wasserstein > 4) poiché il rumore viene scambiato per micro-bordi.



ImageNet-C: Drift Visivo - Categoria Weather


Valori della distanza di Wasserstein per le feature visive sulle corruzioni di tipo Weather (Fog, Snow, Rain, Brightness).



ImageNet-C: Drift Visivo - Categoria Weather, esempio: Fog


Distribuzioni Weather (es. Fog):

- La nebbia appiattisce il contrasto comprimendo le distribuzioni verso un grigio uniforme.
- I canali colore tendono a convergere verso valori medi simili, riducendo la saturazione.
- La nitidezza cala drasticamente a causa della fusione dei bordi.



ImageNet-C: Drift Visivo - Categoria Digital


Valori della distanza di Wasserstein per le feature visive sulle corruzioni di tipo Digital (Contrast, Elastic Transform, JPEG Compression, Pixelate).



ImageNet-C: Drift Visivo - Categoria Digital, esempio: Contrast

Distribuzioni Digital (es. Contrast):

- La manipolazione diretta del contrasto sposta radicalmente la metrica RMS contrast.
- Le medie dei canali colore rimangono stranamente stabili nonostante la forte alterazione visiva.



Discrepanza interessante:


- **Digital & Noise:** Visivamente, il drift per le feature *sharpness* e *contrasto* è sempre alto, anche a severità 1 e 2.
- **Reti Neurali:** Il test MMD **non** rileva drift sulle feature di *avgpool* per i primi livelli di severità per corruzioni come *Contrast*, *Motion Blur*, *Brightness*, o *Gaussian Noise*. Per *JPEG_compression*, non rileva drift a nessuna severità.
- **Significato:** Le caratteristiche utilizzate dalla rete per classificare sono fondamentalmente diverse da quelle estratte staticamente dai pixel dell'immagine.

Metric	IN-1k	IN-R	Delta	Sig.
Accuracy	84.33%	30.34%	53.98%	YES
Top-5 accuracy	96.35%	45.72%	50.63%	YES

- Tutte le metriche calano drasticamente e in modo statisticamente significativo.
- **-53.9% di Accuratezza:** Il Covariate Shift introdotto da un cambio di stile visivo (arte, cartoni, ecc.) devasta la capacità di generalizzazione di ResNet-50.


Degradazione su ImageNet-C: Blur

- La degradazione cresce all'aumentare della severità per tutti i tipi di blur.
- **Glass Blur** ha un crollo drastico non lineare (AUC di Robustness bassissima: 0.369), portando l'accuratezza ben sotto il 10% a severità 5.
- **Zoom Blur** mostra il comportamento di degrado più lineare ($R^2 = 0.99$).




Degradazione su ImageNet-C: Noise

- L'impatto del rumore è quasi lineare e gravissimo.
- Ai primissimi livelli (1-2) il modello regge parzialmente (coerentemente con l'assenza di drift MMD a quei livelli).
- A severità 5 l'accuratezza crolla a $\sim 10\%$.
- **Impulse noise** risulta il peggiore della categoria (AUC Robustness: 0.482).




Degradazione su ImageNet-C: Digital

- Categoria con le performance mediamente più alte.
- **JPEG** e **Contrast** mantengono accuratèzze relativamente buone ($\text{AUC Robustness} > 0.73$), il che si allinea perfettamente con l'assenza di drift MMD sulle feature interne a basse/medie severità.
- **Elastic Transform** fa eccezione: dopo un andamento irregolare crolla precipitosamente a severità 5.



Degradazione su ImageNet-C: Weather

- Varianza notevole tra le diverse condizioni atmosferiche.
- **Brightness** non impatta quasi per nulla il modello, mantenendo un'accuratezza altissima (AUC Robustness: 0.899).
- Anche **Fog** (nebbia) si mantiene moderatamente robusta.
- Al contrario, **Frost** e **Snow** distruggono le performance (AUC Robustness ~ 0.50 - 0.57), probabilmente perché introducono artefatti fisici complessi (cristalli e occlusione) anziché soli cambi cromatici.



- ❶ **Disaccoppiamento Visivo-Rete:** Non esiste una forte correlazione tra il drift calcolato sui pixel "grezzi" (Wasserstein) e il drift interno al modello (MMD). La rete usa logiche e feature molto diverse da quelle misurabili dall'occhio umano.
- ❷ **Correlazione MMD-Performance:** Esiste invece una forte correlazione tra il rilevamento del drift MMD sulle feature di ResNet-50 e l'effettivo calo dell'accuratezza in fase di test.

Confronto di impatto globale:

- A basse severità (1-2), il rumore e le corruzioni fisiche (ImageNet-C) generano un danno nettamente minore rispetto al cambio di stile artistico di ImageNet-R.
- Solo ai livelli estremi (severità 4 e 5), le corruzioni fisiche/digitali arrivano a penalizzare il modello in modo più severo (sotto al 30% di accuratezza).
- **Verdetto finale:** Il covariate shift causato da una variazione concettuale/stilistica (ImageNet-R) è strutturalmente il più difficile da gestire per una CNN addestrata su foto standard, battuto solo da artefatti e degradazioni visive severissime.

Possibili evoluzioni del progetto includono:

- **Drift Temporale:** Analizzare ImageNet-V2, dataset campionato successivamente ma con logiche identiche a ImageNet originale, per testare la riproducibilità temporale e il temporal shift.
- **Altri Shift:** Ripetere l'analisi introducendo *Prior Probability Shift* o *Concept Shift*.
- **Architetture Alternative:** Valutare se modelli concettualmente diversi mostrino una robustezza superiore o diversa rispetto alle CNN in presenza dello stesso drift.

Grazie per l'attenzione!