

Report progetto Architetture Dati: data drift su ImageNet

Analisi delle prestazioni di ResNet-50 su ImageNet-R e ImageNet-C

Daniele Besozzi, Andrea Consonni, Elena Zen

Progetto Architetture Dati

- 1 Introduzione al Data Drift
- 2 I Dataset
- 3 Il Modello: ResNet-50
- 4 Metodologia
- 5 Risultati: Misurazione del Drift
- 6 Risultati: Analisi delle Performance
- 7 Conclusioni e Sviluppi

Il problema del Data Drift

- **Assunzione classica (i.i.d.):** Nel machine learning si assume che i dati di test e di addestramento provengano dalla stessa distribuzione.
- **Realtà operativa:** Spesso questa assunzione è disattesa. La distribuzione cambia nel tempo o nello spazio → **Data drift** o **Distribution shift**.
- **Conseguenza:** Calo significativo delle prestazioni del modello, anche senza alcuna modifica ai suoi pesi o all'architettura.
- **Obiettivo del progetto:** Quantificare l'effetto del drift sulle prestazioni dei modelli di classificazione d'immagini.

Definizione Formale

Secondo Moreno-Torres et al., possiamo definire il **Dataset Shift** come:

Dataset shift

Si verifica quando la distribuzione di probabilità congiunta delle feature x e della variabile target y differisce tra la fase di addestramento (P_{tr}) e la fase di test (P_{tst}).

Formalmente: $P_{tr}(y, x) \neq P_{tst}(y, x)$.

È essenziale distinguere la direzione causale:

- $X \rightarrow Y$: Le feature determinano la classe (es. frodi bancarie).
- $Y \rightarrow X$: La classe determina le feature (es. patologia che causa sintomi).


Covariate Shift (o Population Drift)

- Cambiano le feature in input, ma la classe semantica resta la stessa.
- $P_{tr}(x) \neq P_{tst}(x)$ e $P_{tr}(y|x) = P_{tst}(y|x)$.
- È la forma di drift indagata in questo progetto (variazioni di stile, perturbazioni visive).


dogs in water




cats in grass



dogs in grass



cats in water



Altre Tipologie e Cause

Prior Probability Shift

Cambia la frequenza delle classi ($P(y)$ fluttua), ma la distribuzione delle feature data la classe resta uguale. Tipico della diagnostica (epidemie).

Concept Shift

Cambia la definizione stessa della classe da apprendere ($P_{tr}(y|x) \neq P_{tst}(y|x)$). Esempio: spammer che cambiano tattiche per ingannare i filtri.

Cause principali del drift:


- Sample Selection Bias (campionamento non uniforme).
- Ambienti Non Stazionari (dinamismo temporale e spaziale).

ImageNet-1k (La Baseline)

- Derivato dall'enorme ImageNet-21k (14.2M di immagini, mappatura su WordNet).
- **ImageNet-1k** contiene 1.000 classi specifiche poste alla base dell'albero gerarchico.
- Utilizzato originariamente per la competizione ILSVRC.
- **Nel progetto:** Utilizziamo il validation set di 50.000 immagini come benchmark **in-distribution** per stabilire le prestazioni ottimali del modello.


ImageNet-C (Corruzioni)

- Costruito applicando sistematicamente **corruzioni digitali** sulle stesse 50.000 immagini del validation set di ImageNet-1k.
- Obiettivo: imitare limitazioni fisiche dei sensori, compressioni e variazioni atmosferiche.
- Struttura gerarchica:
 - 15 tipi di corruzioni in 4 categorie (*Blur*, *Noise*, *Digital*, *Weather*).
 - 5 livelli di intensità (severità).
- Totale: 3.750.000 immagini di test.




ImageNet-R (Rendition)

- Valuta il modello su **immagini stilizzate e artistiche**.
- Selezionato un subset di **200 classi** di ImageNet-1k, reperite via web scraping su Flickr.
- Immagini etichettate per stili: *art, cartoon, graffiti, painting, sculpture, toy, origami*, ecc.
- Filtro di qualità manuale tramite Amazon Mechanical Turk.
- Totale: ~ 30.000 immagini di test (media 150 per classe).



Reti Neurali Convulsive (CNN)

- Capaci di sfruttare le **caratteristiche spaziali** dell'input visivo (es. correlazione tra pixel vicini).
- **Vantaggio:** Riducono drasticamente i parametri rispetto a reti fully-connected usando filtri condivisi (*kernel*).
- Architettura base formata da: Strati Convolutivi, Strati di Pooling, Strati Fully-Connected.




Esempio storico: Architettura LeNet-5

Estrazione delle Feature Maps

Nei layer convolutivi, il kernel "scorre" sull'immagine estraendo caratteristiche.

- Un kernel mappa regioni locali.
- Viene applicata una funzione di attivazione non lineare.
- Layer profondi imparano feature sempre più complesse e astratte.





Il problema della degradazione e le ResNet


Problema: Aumentando i layer, l'accuratezza satura e poi decade (non a causa dell'overfitting).

Soluzione (Reti Residuali):

- Apprendimento residuale: imparare la differenza $\mathcal{F}(x)$ invece della mappa completa.
- Uso di **Identity shortcut connections**: connessioni che saltano uno o più layer, facilitando l'ottimizzazione.



"Basic"
Residual block



"Bottleneck"
Residual block

- **Librerie:** Sviluppo in PyTorch, elaborazione dataset tramite HuggingFace e Arrow per l'efficienza. Evidenze di drift tramite Evidently.
- **Filtro Dataset:** Per il test su ImageNet-R, ImageNet-1k è stato filtrato mantenendo solo le 200 classi in comune, per garantire un confronto paritario.
- **Inferenza:** Uso di **ResNet-50** con pesi pre-addestrati (senza fine-tuning). Rilevate predizioni ed estratte le feature del penultimo layer (avgpool).
- **Metriche:** Calcolate Accuracy, Balanced Accuracy, Precision, Recall, F1, MCC e Cohen's Kappa su 5 ripetizioni con *augmentation stocastica* per stimare gli Intervalli di Confidenza (Test t di Welch).

L'analisi del drift è stata condotta a due livelli:


- ① **Sulle proprietà visive:** Estrazione di Luminosità, Contrasto RMS, Nitidezza (Sharpness) e medie dei canali RGB (tramite PIL).
 - Misurato tramite **Distanza di Wasserstein** (soglia di drift: 0.1).
- ② **Sulle feature di rete:** Vettori a 2048 dimensioni estratti internamente dal modello.
 - Misurato tramite Test **Empirical MMD** (Maximum Mean Discrepancy, drift se $p\text{-value} < 0.05$).

Drift Visivo su ImageNet-R

La maggior parte delle feature presenta drift rispetto a ImageNet-1k.

- Drift significativo ovunque eccetto che per la *sharpness*.
- Alta varianza per la *brightness* (molte immagini artistiche hanno sfondi bianchi).

Confronto delle distribuzioni delle feature: ImageNet-1k vs ImageNet-R
Drift quando WD ≥ 0.1



Drift sulle Feature della Rete (MMD)

Anche internamente al modello, ImageNet-R genera un forte **Drift Latente**.

dataset	is_drift	p_val	distance
ImageNetR	True	0.0000	0.0805


- p-value pari a 0 (sotto la soglia 0.05).
- Coerente con il drift rilevato visivamente.

ImageNet-C: Drift Visivo - Categoria Blur

Distribuzioni Blur (es. *Glass Blur* / *Defocus*):

- Luminosità e canali colore non presentano variazioni significative.
- Il contrasto e la nitidezza subiscono un forte slittamento a causa della fusione dei bordi.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: glass_blur




ImageNet-C: Drift Visivo - Categoria Noise

Distribuzioni Noise (es. *Gaussian / Shot Noise*):

- Il rumore elettronico o termico altera pesantemente le alte frequenze.
- La *sharpness* schizza a valori elevatissimi (distanza di Wasserstein > 4) poiché il rumore viene scambiato per micro-bordi.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: gaussian_noise




ImageNet-C: Drift Visivo - Categoria Weather

Distribuzioni Weather (es. Fog / Snow):

- La nebbia appiattisce il contrasto comprimendo le distribuzioni verso un grigio uniforme.
- La neve altera la luminosità e crea picchi anomali di nitidezza grazie ai fiocchi definiti.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: fog




ImageNet-C: Drift Visivo - Categoria Digital

Distribuzioni Digital (es. Contrast / Elastic Transform):

- La manipolazione diretta del contrasto sposta radicalmente la metrica RMS contrast.
- Le medie dei canali colore rimangono incredibilmente stabili nonostante la forte alterazione visiva.

Distribuzioni delle feature: ImageNet-1k vs ImageNet-C. Sporcatura: contrast



Discrepanza interessante:

- **Digital & Noise:** Visivamente, il drift per le feature *sharpness* e *contrasto* è sempre alto, anche a severità 1 e 2.
- **Reti Neurali:** Il test MMD **non** rileva drift sulle feature di *avgpool* per i primi livelli di severità per corruzioni come *Contrast*, *Motion Blur* o *Gaussian Noise*. Per *JPEG_compression*, non rileva drift a nessuna severità.
- **Significato:** Le caratteristiche utilizzate dalla rete per classificare sono fondamentalmente diverse da quelle estratte staticamente dai pixel dell'immagine.


Impatto di ImageNet-R sulle Metriche

Metric	IN-1k	IN-R	Delta	Sig.
Accuracy	84.33%	30.34%	53.98%	YES
Top-5 accuracy	96.35%	45.72%	50.63%	YES
F1 weighted	89.62%	41.78%	47.84%	YES

- Tutte le metriche calano drasticamente e in modo statisticamente significativo.
- **-53.9% di Accuratezza:** Il Covariate Shift introdotto da un cambio di stile visivo (arte, cartoni, ecc.) devasta la capacità di generalizzazione di ResNet-50.


Degradazione su ImageNet-C: Blur

- La degradazione cresce all'aumentare della severità per tutti i tipi di blur.
- **Glass Blur** ha un crollo drastico non lineare (AUC bassissima: 0.369), portando l'accuratezza ben sotto il 10% a severità 5.
- **Zoom Blur** mostra il comportamento di degrado più lineare ($R^2 = 0.99$).




Degradazione su ImageNet-C: Noise

- L'impatto del rumore è quasi lineare e gravissimo.
- Ai primissimi livelli (1-2) il modello regge parzialmente (coerentemente con l'assenza temporanea di drift MMD).
- A severità 5 l'accuratezza crolla irrimediabilmente a $\sim 10\%$.
- **Impulse noise** risulta il peggiore della categoria (AUC 0.482).




Degradazione su ImageNet-C: Digital

- Categoria con le performance mediamente più alte.
- **JPEG** e **Contrast** mantengono accuratèzze relativamente buone ($AUC > 0.73$), il che si allinea perfettamente con l'assenza di drift MMD sulle feature interne a basse/medie severità.
- **Elastic Transform** fa eccezione: dopo un andamento stabile crolla precipitosamente a severità 5.



Degradazione su ImageNet-C: Weather

- Varianza notevole tra le diverse condizioni atmosferiche.
- **Brightness** non impatta quasi per nulla il modello, mantenendo un'accuratezza altissima (AUC 0.899).
- Anche **Fog** (nebbia) si mantiene moderatamente robusta.
- Al contrario, **Frost** e **Snow** distruggono le performance (AUC ~ 0.50 - 0.57), probabilmente perché introducono artefatti fisici complessi (cristalli e occlusione) anziché soli cambi cromatici.



- 1 **Disaccoppiamento Visivo-Rete:** Non esiste una forte correlazione tra il drift calcolato sui pixel "grezzi" (Wasserstein) e il drift interno al modello (MMD). La rete usa logiche e feature molto diverse da quelle misurabili dall'occhio umano.
- 2 **Correlazione MMD-Performance:** Esiste invece una forte correlazione tra il rilevamento del drift MMD sulle feature di ResNet-50 e l'effettivo calo dell'accuratezza in fase di test.

Confronto di impatto globale:

- A basse severità (1-2), il rumore e le corruzioni fisiche (ImageNet-C) generano un danno nettamente minore rispetto al cambio di stile artistico di ImageNet-R.
- Solo ai livelli estremi (severità 4 e 5), le corruzioni fisiche/digitali arrivano a penalizzare il modello in modo più severo (sotto al 30% di accuratezza).
- **Verdetto finale:** Il covariate shift causato da una variazione concettuale/stilistica (ImageNet-R) è strutturalmente il più difficile da gestire per una CNN addestrata su foto standard, battuto solo da artefatti e degradazioni visive severissime.

Possibili evoluzioni del progetto includono:

- **Drift Temporale:** Analizzare ImageNet-V2, dataset campionato successivamente ma con logiche identiche a ImageNet originale, per testare la riproducibilità temporale e il natural shift.
- **Altri Shift:** Ripetere l'analisi introducendo *Prior Probability Shift* (classi sbilanciate artificialmente) o *Concept Shift* (attacchi avversariali attivi).
- **Architetture Alternative:** Valutare se modelli concettualmente diversi, come i **Vision Transformers (ViT)**, mostrino una robustezza superiore o diversa rispetto alle CNN in presenza dello stesso drift.

Grazie per l'attenzione!